

UNIVERSIDADE DO ESTADO DO AMAZONAS - UEA

ESCOLA SUPERIOR DE TECNOLOGIA

ENGENHARIA DE COMPUTAÇÃO

**ANÁLISE COMPARATIVA DE DETECTORES *SINGLE-STAGE*
PARA A IDENTIFICAÇÃO DE MALÁRIA**

MANAUS – JUNHO – 2025

LEONARDO MONTEIRO NERES DE LIMA

**ANÁLISE COMPARATIVA DE DETECTORES *SINGLE-STAGE*
PARA A IDENTIFICAÇÃO DE MALÁRIA**

Trabalho de Conclusão de Curso apresentado à banca avaliadora do Curso de Engenharia de Computação, da Escola Superior de Tecnologia, da Universidade do Estado do Amazonas, como pré-requisito para obtenção do título de Engenheiro de Computação.

Orientadora: Profa. Dra. Elloá B. Guedes

Manaus – Junho – 2025

Universidade do Estado do Amazonas - UEA
Escola Superior de Tecnologia - EST

Reitor:

André Luiz Nunes Zogahib

Vice-Reitora:

Kátia do Nascimento Couceiro

Diretor da Escola Superior de Tecnologia:

Jucimar Maia Júnior

Coordenador do Curso de Engenharia de Computação:

Raimundo Correa de Oliveira

Coordenadora da Disciplina Trabalho de Conclusão de Curso II:

Polianny Almeida Lima

Banca Avaliadora composta por:

Data da Defesa: 18/06/2025

Prof.^a Dra. Elloá Barreto Guedes da Costa (Orientadora)

Prof.^a Dra. Áurea Hiléia da Silva Melo

Prof.^a MSc. Danielle Gordiano Valente

Ficha Catalográfica

Ficha catalográfica elaborada automaticamente de acordo com os dados fornecidos pelo(a) autor(a).

Sistema Integrado de Bibliotecas da Universidade do Estado do Amazonas.

L732a Lima, Leonardo Monteiro Neres de
 Análise Comparativa de Detectores Single-Stage para a
 Identificação de Malária / Leonardo Monteiro Neres de Lima . Manaus :
 [s.n], 2025.
 59 f.: color.; 21,0 cm.

 TCC - Graduação em Engenharia de Computação- Universidade do
Estado do Amazonas, Manaus, 2025.
 Inclui Bibliografia.
 Orientador: Guedes, Elloá B..

 1. Detecção de objetos. 2. Malária. 3. YOLO. 4. SSD. 5. Visão
computacional. I. Guedes, Elloá B. (Orient.) II. Universidade do Estado
do Amazonas. III. Título

CDU(1997)62:004

Resumo

A detecção automatizada de malária por meio de técnicas de visão computacional representa uma abordagem promissora para superar os desafios diagnósticos em regiões endêmicas, frequentemente caracterizadas por escassez de especialistas e infraestrutura limitada. Este trabalho apresenta um estudo comparativo entre os detectores de objetos SSD300 e YOLOv12n, aplicados à identificação de parasitas da malária em imagens de gota espessa de sangue. Os modelos foram treinados utilizando estratégias de avaliação por meio de métricas como mAP@50, precisão, recall e F1-score, além de análises qualitativas das detecções. Os resultados indicaram que o YOLOv12n obteve desempenho global superior, com mAP@50 de 74,7 % e F1-score de 59,9 %, superando o SSD300, que alcançou 64,0 % de mAP@50 e F1-score de 8,0 %. A análise visual confirmou esses achados, mostrando que enquanto o SSD300 possui maior recall, sofre com baixa precisão em imagens complexas. Em contraste, o YOLOv12n oferece melhor equilíbrio entre sensibilidade e acurácia de localização, mesmo com menos parâmetros. A principal contribuição deste estudo é destacar o potencial de detectores *single-stage* como ferramentas acessíveis e escaláveis para apoiar o diagnóstico de malária, contribuindo para triagem automatizada em locais com poucos recursos.

Palavras-chave: Detecção de objetos; Malária; YOLO; SSD; Visão computacional.

Abstract

Automated malaria detection through computer vision techniques represents a promising approach to overcome diagnostic challenges in endemic regions, often characterized by a shortage of specialists and limited infrastructure. This work presents a comparative study between the object detectors SSD300 and YOLOv12n, applied to the identification of malaria parasites in thick blood smear images. The models were trained using evaluation strategies through metrics such as mAP@50, precision, recall, and F1-score, in addition to qualitative analyses of the detections. The results indicated that YOLOv12n achieved superior overall performance, with a mAP@50 of 74,7% and an F1-score of 59,9%, surpassing SSD300, which reached 64,0% mAP@50 and an F1-score of 8,0%. The visual analysis confirmed these findings, showing that while SSD300 yields higher recall, it suffers from low precision in complex images. In contrast, YOLOv12n provides a better balance between sensitivity and localization accuracy, even with fewer parameters. The main contribution of this study is to highlight the potential of single-stage detectors as accessible and scalable tools to support malaria diagnosis, contributing to automated screening in low-resource settings.

Keywords: *Object detection; Malaria; YOLO; SSD; Computer Vision.*

Agradecimentos

Gostaria de expressar minha profunda gratidão à minha família nuclear, composta por meu pai, minha mãe e minhas irmãs, pela base afetiva, racional e social que me foi ofertada ao longo da vida. Ao longo da minha trajetória, uma rede de experiências e escolhas me proporcionou o suporte necessário para minha formação humana e intelectual, que posteriormente serviria de subsídio para o desenvolvimento da autoestima. Essa autoestima atuou como limiar fundamental para a motivação na execução das atividades relacionadas a este trabalho. Destaco, com especial apreço, a oportunidade de ter cursado o ensino médio integrado ao curso técnico em Informática, o que foi essencial para o desenvolvimento inicial da minha base em computação.

Aos amigos e colegas de caminhada, agradeço não apenas pela companhia, mas por colaborarem com a manutenção de minha perspectiva de vida, mesmo nos momentos de maior dificuldade. Suas presenças foram fundamentais para sustentar o ânimo e a continuidade do percurso acadêmico.

Agradeço também à minha prezada orientadora, Profa. Dra. Elloá B. Guedes, pela orientação precisa, pelo incentivo contínuo à busca por soluções criativas com rigor técnico e, de modo especial, pela motivação transmitida ao longo da execução deste trabalho. Sua condução foi determinante para que este projeto se concretizasse.

À Universidade do Estado do Amazonas e ao corpo docente do curso de Engenharia de Computação, agradeço pelo espaço de aprendizado, reflexão e desenvol-

vimento científico que permitiram a consolidação desta pesquisa.

Por fim, deixo registrado meu reconhecimento a todas as pessoas e instituições que, direta ou indiretamente, contribuíram para a concretização deste projeto.

Sumário

Lista de Tabelas	ix
Lista de Figuras	xi
1 Introdução	1
1.1 Objetivos	3
1.2 Justificativa	3
1.2.1 Metodologia	5
1.3 Apresentação do Documento	6
2 Fundamentação Teórica	7
2.1 Aspectos Clínicos e Epidemiológicos da Malária	8
2.2 Redes Neurais Artificiais	10
2.3 Detecção de Objetos e Redes Convolucionais	17
2.4 Modelos de Detecção <i>Single-Stage</i>	21
2.4.1 YOLO	21
2.4.2 <i>Single-Shot Detectors (SSD)</i>	25
2.5 Trabalhos Relacionados	30

3	Materiais e Métodos	35
3.1	Dados Experimentais: Análise Exploratória e Preparação Experi- mental	35
3.2	Modelos e Parametrização	39
3.3	Avaliação de Desempenho	42
3.4	Tecnologias Utilizadas	44
4	Resultados e Discussão	47
5	Considerações Finais	54

Lista de Tabelas

2.1	Comparação entre trabalhos relacionados	34
3.1	Descrição estatística das quantidades de imagens e <i>caixas delimitadoras</i> nas bases de dados selecionadas.	36
3.2	Descrição estatística das <i>dimensões</i> das <i>caixas delimitadoras</i> normalizadas pelas dimensões das imagens	37
4.1	Comparação de desempenho entre diferentes variantes do modelo YOLOv12 e SSD na tarefa de detecção de malária.	50

Lista de Figuras

2.1	Princípio de funcionamento de um neurônio artificial (KRENKER; BESTER; KOS, 2011).	11
2.2	Três tipos diferentes de função de transferência: escalonada, sigmóide e linear em formatos unipolares e bipolares (PRIDDY, 2005).	12
2.3	Modelo de neurônio simples com limites de decisão (PRIDDY, 2005).	12
2.4	Topologia feed-forward (FNN) e recorrente (RNN) de uma rede neural artificial. (KRENKER; BESTER; KOS, 2011).	13
2.5	A rede neural feedforward multicamadas forma regiões de decisão complexas para resolver problemas separáveis não linearmente (PRIDDY, 2005).	14
2.6	Exemplo de Convolução 2D – A matriz de saída é denominada mapa de características (<i>features maps</i>) (FARIA, 2018).	20
2.7	Esquema de detecção do YOLO (REDMON et al., 2016).	22
2.8	Arquitetura da rede YOLO para detecção de objetos (REDMON et al., 2016).	24

2.9	Uma comparação entre dois modelos de detecção de disparo único (<i>single shot</i>): SSD e YOLO (REDMON et al., 2016). Nosso modelo SSD adiciona várias camadas de recursos ao final de uma rede base, que preveem os deslocamentos para caixas padrão de diferentes escalas e relações de aspecto, bem como suas respectivas confianças. O SSD com tamanho de entrada de 300×300 supera significativamente seu equivalente YOLO de 448×448 em precisão no teste VOC2007, além de melhorar a velocidade de execução, embora a rede personalizada do YOLO seja mais rápida que o VGG16 (LIU et al., 2016).	28
3.1	Comparação de imagens com diferentes quantidades de caixas delimitadoras do conjunto de dados.	37
3.2	Histograma da quantidade de <i>caixas delimitadoras</i> por imagens do conjunto de Treino	38
3.3	Histograma da quantidade de <i>caixas delimitadoras</i> por imagens do conjunto de Teste	38
3.4	Histograma da quantidade de <i>caixas delimitadoras</i> por Faixa de área do conjunto de treino	39
3.5	Histograma da quantidade de <i>caixas delimitadoras</i> por faixa de área do conjunto de teste	40
4.1	Métricas de treino do modelo SSD300.	48
4.2	Métricas de treino do modelo YOLOv12 versão nano.	48
4.3	Detecção SSD300	50
4.4	Detecção YOLOv12 nano	51

Capítulo 1

Introdução

A malária é uma doença infecciosa causada por protozoários do gênero *Plasmodium*, transmitida ao ser humano por fêmeas do mosquito *Anopheles*, com destaque para a espécie *Anopheles darlingi* na região amazônica (BRASIL, 2010). Apesar da existência de tratamento eficaz, a malária ainda constitui um sério problema de saúde pública global. Em 2022, a Organização Mundial da Saúde (OMS) estimou cerca de 241 milhões de casos e 627 mil óbitos pela doença no mundo, com 95% dessas mortes ocorrendo na África, majoritariamente entre crianças (OMS, 2022). No Brasil, 99,9% dos casos autóctones se concentram na região amazônica, afetando especialmente áreas rurais, indígenas e de garimpo, que juntas corresponderam a 94,1% dos casos notificados em 2022 (BRASIL, 2024).

O diagnóstico de malária, especialmente nessas regiões, é geralmente realizado por meio da análise microscópica da gota espessa de sangue, método considerado padrão-ouro pela sua sensibilidade e especificidade (BRASIL, 2009). Entretanto, essa abordagem depende fortemente da experiência do examinador e apresenta grande variabilidade intra e interobservador, o que pode comprometer a precisão

diagnóstica, sobretudo em áreas com escassez de profissionais qualificados.

Diante das limitações do diagnóstico microscópico convencional, têm sido propostas abordagens baseadas em Visão Computacional e *Deep Learning* para automatizar a detecção de parasitas da malária em lâminas de gota espessa (ALBUQUERQUE; GUEDES, 2023). Entre essas abordagens, destacam-se detectores de objetos do tipo *two-stage*, como os modelos da família R-CNN, e os do tipo *single-stage*, como a linha YOLO, incluindo o YOLOv7x. Esses modelos têm apresentado desempenho expressivo em tarefas de detecção de malária, alcançando valores de F_1 -score e mAP superiores a 80%. No entanto, a complexidade computacional de algumas dessas arquiteturas, como o YOLOv7x, que possui aproximadamente 70,7 milhões de parâmetros, representa um potencial fator de inviabilidade para sua implementação em cenários com infraestrutura limitada, como é o caso de regiões endêmicas e de difícil acesso, onde a capacidade de hardware é restrita. Nesses contextos, o uso de soluções embarcadas e dispositivos móveis representa uma alternativa viável para apoiar o diagnóstico local. Nesse cenário, modelos *single-stage*, por realizarem a tarefa de detecção de objetos em uma única etapa, oferecem vantagens como menor tempo de inferência e menor demanda computacional (REDMON et al., 2016).

Diante disso, este trabalho propõe e avalia o uso de detectores *single-stage*, como SSD (do inglês *Single Shot Detectors*) e YOLO (do inglês *You Only Look Once*), para a detecção automática de parasitas da malária em imagens microscópicas de gota espessa.

1.1 Objetivos

O objetivo geral deste trabalho consistiu em avaliar a eficácia e eficiência de modelos *single-stage* na tarefa de detecção de parasitas de malária em imagens microscópicas obtidas pelo método da gota espessa. Para alcançar essa meta, os objetivos específicos a seguir foram contemplados:

1. Realizar uma revisão da literatura para identificar e selecionar estudos relevantes que forneçam imagens microscópicas de sangue com parasitas da malária;
2. Implementar e treinar modelos SSD com *triplet loss* e da família YOLOv12 com diferentes arquiteturas, utilizando a base de dados de imagens de malária preparada concebido em cenário experimental;
3. Avaliar e realizar análise comparativa, quantitativa e qualitativa dos resultados obtidos.

1.2 Justificativa

A malária ainda representa um grave problema de saúde pública, especialmente em regiões tropicais como a Amazônia brasileira, onde há elevada incidência da doença e escassez de profissionais especializados. O diagnóstico laboratorial, feito majoritariamente por meio de análise visual de amostras de sangue sob microscópio, depende fortemente da expertise do examinador e está sujeito a falhas causadas por fadiga, vieses inconscientes e falta de padronização. Soluções automatizadas baseadas em Visão Computacional podem mitigar esses problemas, acelerando e

aprimorando o diagnóstico, com potencial impacto direto no prognóstico dos pacientes.

Nesse contexto, modelos de detecção de objetos do tipo *Single-Stage*, como os SSD e as versões da família YOLO (*You Only Look Once*), surgem como alternativas promissoras. Em contraste com modelos *Two-Stage*, como o Faster R-CNN, os modelos *Single-Stage* realizam a detecção e a classificação em uma única etapa, o que proporciona maior velocidade de inferência e menor demanda computacional. Essas características os tornam particularmente adequados para aplicações embarcadas em dispositivos com recursos limitados, como smartphones e sistemas portáteis de apoio ao diagnóstico. Neste trabalho, opta-se por avaliar e comparar diferentes arquiteturas *Single-Stage* na tarefa de detecção de parasitas da malária em imagens de gota espessa, com o objetivo de identificar soluções leves, eficazes e com desempenho compatível com os requisitos operacionais de uso em campo por agentes de saúde para auxílio no diagnóstico.

Do ponto de vista acadêmico, o desenvolvimento deste trabalho proporciona ao discente a aplicação prática de conceitos de Redes Neurais Artificiais, Álgebra Linear, Processamento Digital de Imagens e Inteligência Artificial, integrando teoria e prática em um problema de relevância real. Além disso, a proposta está alinhada às linhas de pesquisa do Laboratório de Sistemas Inteligentes (LSI) da Escola Superior de Tecnologia da UEA, contribuindo para o avanço de soluções tecnológicas aplicadas à saúde.

1.2.1 Metodologia

A metodologia utilizada para o desenvolvimento das atividades presentes neste trabalho, com o intuito de atingir os objetivos especificados, é descrita a seguir:

1. Estudo dos conceitos e fundamentos teóricos relacionados aos modelos *Single-Stage* (SSD e YOLO) aplicados à tarefa de detecção de objetos em Visão Computacional;
2. Levantamento e análise do ferramental tecnológico necessário para implementação dos modelos SSD e YOLOv12, incluindo bibliotecas, frameworks e recursos computacionais;
3. Identificação, análise exploratória e preparação de uma base de dados disponível na literatura, voltada para a detecção de parasitas da malária em imagens de gota espessa;
4. Seleção de arquiteturas SSD e YOLOv12 representativas do estado da arte;
5. Concepção do cenário experimental para avaliação dos modelos SSD300 e da família YOLOv12 para detecção de malária
6. Treinamento dos modelos com métricas de desempenho;
7. Aferição de métricas de desempenhos dos modelos nos testes
8. Análise crítica dos resultados;
9. Escrita do Trabalho de Conclusão de Curso II;
10. Defesa do Trabalho de Conclusão de Curso II;

1.3 Apresentação do Documento

Este trabalho está estruturado em seis capítulos. O Capítulo 2 aborda a fundamentação teórica necessária para o entendimento dos principais conceitos relacionados à malária, redes neurais e modelos de detecção de objetos, com ênfase nos algoritmos *single-stage*, como SSD e YOLO, também revisa os principais trabalhos relacionados. O Capítulo 3 descreve a metodologia empregada, incluindo os procedimentos de preparação dos dados, configuração dos experimentos e métricas utilizadas. O Capítulo 4 apresenta e discute os resultados obtidos na comparação entre os modelos SSD300 e YOLO, com base nos critérios de desempenho. Por fim, o Capítulo 5 traz as considerações finais, apontando as conclusões da pesquisa, suas limitações e propostas para trabalhos futuros.

Capítulo 2

Fundamentação Teórica

O presente capítulo reúne os fundamentos teóricos que sustentam o desenvolvimento deste trabalho. Inicialmente, são apresentados os aspectos clínicos, epidemiológicos e diagnósticos da malária, a fim de contextualizar o problema de saúde pública abordado. Em seguida, discute-se o funcionamento das Redes Neurais Artificiais na Seção 2.2. Na sequência, a Seção sobre detecção de objetos introduz os principais conceitos de Visão Computacional e Redes Neurais Convolucionais aplicadas à identificação de padrões em imagens. Posteriormente, a Seção 2.4.2 descreve os modelos de detecção *single-stage*, com ênfase nas arquiteturas SSD e YOLO. Por fim, a Seção 2.5 apresenta e analisa trabalhos relacionados na literatura, evidenciando lacunas e contribuições anteriores no campo da detecção automática de parasitas da malária.

2.1 Aspectos Clínicos e Epidemiológicos da Malária

A malária é uma doença infecciosa causada por protozoários do gênero *Plasmodium*, transmitida ao ser humano por meio da picada de fêmeas infectadas do mosquito *Anopheles*, sendo a espécie *Anopheles darlingi* a mais relevante na região amazônica (BRASIL, 2010). Os criadouros preferenciais desse vetor incluem coleções de água limpa, quente, sombreada e de baixo fluxo.

As quatro espécies principais de *Plasmodium* que infectam seres humanos são: *P. falciparum*, *P. vivax*, *P. malariae* e *P. ovale*. Após a picada, os esporozoítos migram até o fígado, onde se desenvolvem por cerca de uma semana (ou até duas semanas, no caso do *P. malariae*). Após essa fase hepática, o parasita entra na corrente sanguínea e invade as hemácias, iniciando ciclos de multiplicação eritrocitária com rompimento celular a cada 48 a 72 horas, dependendo da espécie (ANTINORI et al., 2012).

Os sintomas da malária incluem febre irregular, dor de cabeça, fadiga, náuseas, vômitos, anemia leve, icterícia e dores musculares (MIRANDA et al., 2010). Em infecções graves por *P. falciparum*, podem ocorrer manifestações severas como coma (malária cerebral), edema pulmonar, hipoglicemia, insuficiência renal, hemorragias, acidose metabólica e até mesmo óbito (WHITE et al., 2014). A letalidade aumenta significativamente quando a parasitemia ultrapassa 2 % (GOMES et al., 2011).

O diagnóstico clínico é limitado pela inespecificidade dos sintomas, que se assemelham aos de outras doenças infecciosas como dengue, febre amarela e leptospirose (FILHO et al., 2003). Por esse motivo, é necessária a confirmação laboratorial, geralmente feita por meio da microscopia da gota espessa de sangue que é consi-

derada o padrão-ouro (BRASIL, 2009). Esse exame permite detectar parasitemias tão baixas quanto 5 à 10 parasitos por microlitro de sangue, quando realizado por profissionais experientes. No entanto, em condições de campo, a sensibilidade real tende a ser reduzida, com limites em torno de 100 parasitos/ $\mu\ell$.

O tratamento da malária visa interromper o ciclo do parasita em diferentes fases, utilizando esquemas terapêuticos que combinam antimaláricos conforme a espécie infectante. A taxa de cura em casos não complicados por *P. falciparum* varia entre 90% e 95% (PRYCE et al., 2022).

Segundo a Organização Mundial da Saúde (OMS), foram registrados cerca de 241 milhões de casos de malária e 627 mil óbitos em 2022, dos quais 95% ocorreram na África, principalmente entre crianças (OMS, 2022). No Brasil, embora haja investimentos contínuos em vigilância e controle vetorial, a malária ainda representa um desafio relevante. Em 2022, foram notificados 131.224 casos, concentrando-se 99,9% na região amazônica (BRASIL, 2024). As populações mais afetadas são aquelas em áreas rurais (37,3%), indígenas (31%) e de garimpo (17,9%) — locais onde a infraestrutura de saúde costuma ser limitada.

Essa combinação de fatores, composta pela gravidade clínica potencial, pelas limitações do diagnóstico convencional e pela vulnerabilidade das populações atingidas, justifica a busca por soluções tecnológicas que ampliem o acesso a um diagnóstico confiável, rápido e padronizado, como é o caso das abordagens baseadas em Visão Computacional, redes neurais artificiais e mais especificamente *Deep Learning*.

2.2 Redes Neurais Artificiais

O cérebro humano, uma intrincada rede de mais de 10 bilhões de neurônios interconectados, é capaz de realizar tarefas perceptivas complexas como reconhecimento facial e de fala, além de controlar movimentos corporais e funções fisiológicas. Cada neurônio, uma célula que utiliza reações bioquímicas para receber, processar e transmitir informações, se comunica com outros através de sinapses, um processo químico complexo no qual substâncias específicas são liberadas. As condições locais no neurônio, como o bombeamento de sódio e potássio, alteram seu potencial elétrico e, ao atingir um determinado limiar, um pulso elétrico é enviado pelo axônio, fazendo a célula “disparar” (SYDENHAM; THORN, 2005).

Uma Rede Neural Artificial (RNA) é um modelo matemático que tenta simular a estrutura e funcionalidades de redes neurais biológicas. O bloco de construção básico de toda rede neural artificial é o neurônio artificial, ou seja, um modelo matemático simples (função). Tal modelo possui três conjuntos simples de regras: multiplicação, soma e ativação. Na entrada do neurônio artificial as entradas são ponderadas, o que significa que cada valor de entrada é multiplicado pelo peso individual. Na seção intermediária do neurônio artificial está a função de soma que opera sobre todas as entradas ponderadas e tendências. Na saída do neurônio artificial, a soma das entradas e polarizações previamente ponderadas passa pela função de ativação, também chamada de função de transferência (Figura 2.1) (KRENKER; BESTER; KOS, 2011).

As redes neurais artificiais, inspiradas no funcionamento biológico dos neurônios, utilizam funções de transferência para representar o envio de sinais entre neurônios através do potencial de ação. Rosenblatt, em 1958, introduziu o percep-




Figura 2.1: Princípio de funcionamento de um neurônio artificial (KRENKER; BESTER; KOS, 2011).

tron, um neurônio com função de transferência limitadora rígida capaz de resolver problemas simples, atuando como um solucionador de equações lineares com um limite de decisão linear (ROSENBLATT, 1958). A combinação e uso seletivo desses limites de decisão é o que torna as redes neurais artificiais poderosas, permitindo que máquinas aprendam a partir de dados e formem regiões de decisão complexas, atuando como verdadeiros motores computacionais orientados por dados. Essas redes podem combinar regiões de decisão para criar níveis de abstração cada vez mais altos, resultando em propriedades surpreendentes. Um exemplo disso é a formação de um limite de decisão linear por um neurônio, como ilustrado na Figura 2.3, onde um círculo e uma elipse representando diferentes classes (mamíferos e aves) são separados por linhas que representam o locus dos valores de ativação do




Figura 2.2: Três tipos diferentes de função de transferência: escalonada, sigmóide e linear em formatos unipolares e bipolares (PRIDY, 2005).

neurônio para diferentes pesos (PRIDY, 2005).




Figura 2.3: Modelo de neurônio simples com limites de decisão (PRIDY, 2005).

Para aproveitar a complexidade matemática proporcionada pela interconexão de neurônios artificiais, sem torná-la incontrolável, pesquisadores desenvolveram

topografias padronizadas de redes neurais artificiais. Essas topografias, que facilitam a resolução de problemas específicos, precisam ser ajustadas tanto em sua estrutura quanto em seus parâmetros. A escolha da topologia e do paradigma de aprendizado (supervisionado, não supervisionado ou por reforço) depende do problema a ser resolvido. Independentemente do paradigma escolhido, todos eles utilizam "dados de aprendizado" e "regras de aprendizado" para que a rede neural artificial encontre a resposta de saída adequada aos sinais de entrada (KRENKER; BESTER; KOS, 2011).




Figura 2.4: Topologia feed-forward (FNN) e recorrente (RNN) de uma rede neural artificial. (KRENKER; BESTER; KOS, 2011).

Para uma rede neural *feed-forward* (FNN, do inglês *Feedforward Neural Network*), os neurônios artificiais são definidos em camadas. Cada neurônio de uma camada está conectado aos da camada anterior. A propagação do sinal ocorre das camadas de entrada para a saída, passando pelas camadas ocultas do FNN. A rede neural artificial com topologia feed-forward é chamada de rede neural artificial Feed-Forward e, como tal, tem apenas uma condição: a informação deve fluir da entrada para a saída em apenas uma direção, sem back-loops. Não há limitações quanto ao número de camadas, tipo de função de transferência usada em neurônios artificiais individuais ou número de conexões entre neurônios artificiais individuais

primitiva de sua entrada. Na verdade, a rede representa uma cadeia de composições de funções que transformam uma entrada em um vetor de saída (chamado padrão). A rede é uma implementação particular de uma função composta do espaço de entrada para o espaço de saída, que chamamos de função de rede. O problema de aprendizagem consiste em encontrar a combinação ótima de pesos para que a função de rede se aproxime tanto quanto possível de uma determinada função f não explícita (ROJAS, 1996). O processo de modificação dos pesos em um neurônio ou rede para executar corretamente um mapeamento de entrada-saída desejado é denominado aprendizagem na comunidade de redes neurais (PRIDDY, 2005). David E. Rumelhart introduziu um procedimento de aprendizagem, retropropagação, para redes de unidades semelhantes a neurônios. O procedimento ajusta repetidamente os pesos das conexões na rede de modo a minimizar uma medida da diferença entre o vetor de saída real da rede e o vetor de saída desejado. Como resultado dos ajustes de peso, unidades internas “ocultas” que não fazem parte da entrada ou da saída passam a representar características importantes do domínio da tarefa, e as regularidades na tarefa são capturadas pelas interações dessas unidades (RUMELHART; HINTON; WILLIAMS, 1986).

O algoritmo de retropropagação (BP) é um dos mais populares algoritmos de aprendizagem em redes neurais. Este algoritmo executa uma aproximação à minimização global alcançada pelo método de descida mais íngreme. Como tal, o algoritmo pode ser visto como uma generalização do algoritmo adaptativo de mínimos quadrados médios (LMS). A principal diferença entre BP e LMS é o modelo subjacente; ou seja, o LMS ocupa um combinador linear adaptativo, enquanto o BP trabalha em um perceptron multicamadas (LEUNG; HAYKIN, 1991).

O algoritmo de retropropagação de erro (*error back-propagation*) é realizado

por dentro do paradigma do aprendizado supervisionado e é baseado na regra de aprendizado por correção de erro. A aprendizagem consiste em dois passos através das diferentes camadas de rede: um passo para frente, a propagação, e um passo para trás, a retropropagação. No passo para frente, um padrão de atividade (vetor de entrada) é aplicado aos nós sensoriais da rede e se propaga através da rede, camada por camada. Finalmente, um conjunto de saídas é produzido como a resposta real da rede. Durante o passo de propagação, os pesos sinápticos da rede são todos fixos. Durante o passo para trás, por outro lado, os pesos sinápticos são todos ajustados de acordo com uma regra de correção de erro. Especificamente, a resposta real da rede é subtraída de uma resposta desejada (alvo) para produzir um sinal de erro. Este sinal de erro então é propagado para trás através da rede, contra a direção das conexões sinápticas. Os pesos sinápticos são ajustados para fazer com que a resposta real da rede se mova para mais perto da resposta desejada, em um sentido estatístico. O algoritmo de retropropagação de erro também referido na literatura como algoritmo de retropropagação (*back-propagation*). O processo de aprendizagem realizado com o algoritmo é chamado de aprendizagem por retropropagação (HAYKIN, 2001).

Um perceptron de múltiplas camadas tem três características distintas: a função de ativação deve ser não-linear e suave (diferenciável em qualquer ponto), a rede contém uma ou mais camadas de neurônios ocultos e a rede exibe um alto grau de conectividade. É através dessas características, juntamente com a habilidade de aprender da experiência através de treinamento, que o perceptron de múltiplas camadas deriva seu poder computacional apesar de que não podemos afirmar que o algoritmo de retropropagação forneça uma solução ótima para todos os problemas resolúveis. (HAYKIN, 2001).

2.3 Detecção de Objetos e Redes Convolucionais

A detecção de objetos é uma das tarefas mais relevantes da visão computacional, cujo objetivo é identificar e localizar objetos predefinidos em imagens ou vídeos. A detecção de objetos é amplamente utilizada em diversas áreas, como condução autônoma, reconhecimento facial, reconhecimento de atividades, rastreamento de objetos, anotação de imagens e vídeos. Antes do *Deep Learning*, métodos como HOG, SIFT e LBP, combinados com classificadores SVM e *Random Forest*, eram utilizados. O advento das redes neurais convolucionais e do *dataset* ImageNet revolucionou a área. Modelos como RCNN, SPPNet e Fast RCNN aprimoraram a detecção, mas ainda enfrentavam desafios de velocidade. O Faster RCNN introduziu a RPN e caixas âncora, melhorando o desempenho, mas permanecendo inadequado para aplicações em tempo real. YOLO e SSD surgiram para suprir essa demanda, enquanto RetinaNet e Mask RCNN trouxeram melhorias adicionais. A detecção de objetos pequenos foi aprimorada com a FPN (do inglês *Feature Pyramid Network*), e o DETR (do inglês *Detection Transformer*), utilizando modelos Transformadores, consolidou uma abordagem ponta a ponta para a detecção de objetos (MIR et al., 2023).

As *Redes Neurais Convolucionais* (CNNs, do inglês *Convolutional Neural Networks*) são modelos de aprendizado de máquina amplamente utilizados para dados de alta dimensionalidade, como imagens e vídeos. Sua estrutura se assemelha às redes neurais padrão, mas com uma diferença crucial: cada unidade em uma camada de CNN é um filtro que é convoluído com a entrada, incorporando contexto espacial e reduzindo o número de parâmetros a serem aprendidos. As CNNs são eficazes tanto em aprendizado supervisionado, onde aprendem a mapear imagens

para suas categorias correspondentes, quanto em aprendizado não supervisionado, onde estimam a distribuição subjacente dos dados de entrada. Ao detectar representações abstratas de características, desde simples até complexas, as *CNNs* conseguem prever a categoria correta de uma imagem de entrada, tornando-se ferramentas poderosas em diversas aplicações (KHAN et al., 2018).

O pré-processamento de dados para alimentar uma *CNN* envolve diversas etapas cruciais. Inicialmente, as imagens são divididas em *patches* menores, cada um processado individualmente pela rede. Em seguida, aplica-se a centralização em zero (*mean subtraction*), ajustando os valores dos pixels para que a média seja zero, o que auxilia no aprendizado eficiente da rede e evita vieses. A normalização é então realizada, dividindo os dados pelo desvio padrão de cada dimensão, garantindo que todas as dimensões tenham variância unitária. O PCA Whitening é aplicado para reduzir correlações entre dimensões, descorrelacionando-as e normalizando-as independentemente. Finalmente, a Normalização de Contraste Local (NCL) é utilizada, inspirada em conceitos da neurociência, onde cada pixel é ajustado com base na média e desvio padrão de seus vizinhos, realçando características locais e melhorando a representação dos dados para a *CNN* (KHAN et al., 2018).

Fazendo uma analogia ao modelo neurobiológico, as células simples são representadas no modelo pelas camadas convolucionais, nos quais exibem um mecanismo similar de conectividade local e compartilhamento de pesos. Já as células complexas combinam a ativação de células simples e são representadas na forma de camadas de *pooling*. Após o processamento destas camadas, a ativação da última camada convolucional ou *pooling* é utilizada para alimentar um modelo de classificação. A maioria dos modelos atuais, são compostas de diversas de camadas convolucionais e de *pooling*. O resultado gerado a partir da camada de convolução

é denominado de mapas de características e os mesmos são utilizados como entrada para a próxima camada (*pooling*). Já os resultados gerados a partir da camada de *pooling* é utilizado como entrada para a camada totalmente conectada. Essa camada é responsável em gerar as saídas da rede (FARIA, 2018).

Um mapa de características é obtido efetuando a convolução de uma matriz de entrada por um filtro linear. A convolução é um tipo de operação linear e pode ser considerada como uma característica básica para se identificar uma *CNN*, ou seja, para ser considerada uma *CNN* é preciso que a rede neural utilize a convolução em pelo menos uma de suas camadas. O processo de convolução utilizado nas redes *CNNs* é apresentado na Figura 2.6, na qual a matriz de entrada é representado por uma matriz de tamanho 5×5 (pixels de intensidade de uma imagem, por exemplo) e o filtro apresentado é um filtro específico de tamanho 3×3 , denominado filtro que é responsável por detecção de bordas nas imagens. O objetivo dos filtros utilizados nas *CNNs* é detectar determinadas características nos dados de entrada, sendo assim diferentes valores de filtros podem produzir diferentes mapas de características para um mesmo tipo de dado (imagem ou texto). é realizada uma operação de convolução em uma imagem como entrada e um filtro que é deslizado a um pixel em toda a imagem. Para cada janela que desliza sobre a imagem, o produto entre cada elemento do filtro ou *kernel* (também conhecido como conjuntos de pesos sinápticos) e o elemento de entrada que ele sobrepõe é calculado e os resultados são somados para obter a saída correspondente aquela localização analisada (FARIA, 2018).

A camada de *pooling* desempenha um papel fundamental em sistemas baseados em convolução, reduzindo a dimensionalidade dos mapas de características. Ao combinar um conjunto de valores em um número menor, essa etapa transforma




Figura 2.6: Exemplo de Convolução 2D – A matriz de saída é denominada mapa de características (*features maps*) (FARIA, 2018).

a representação conjunta das características em informações valiosas, preservando o essencial e descartando o irrelevante. Os operadores de *pooling* conferem invariância à transformação espacial e reduzem a complexidade computacional das camadas superiores, eliminando algumas conexões entre camadas convolucionais. Essa camada realiza a subamostragem dos mapas de características da camada anterior, produzindo novos mapas com resolução condensada. Tal processo visa reduzir o número de parâmetros, diminuindo o custo computacional e controlando o sobreajuste, um desafio comum em aprendizado de máquina. Um método de *pooling* ideal deve extrair apenas informações úteis, descartando detalhes irrelevantes para a tarefa em questão. Os métodos mais populares são *Average Pooling*, *Max-Pooling*, *Mixed Pooling*, *L_p Pooling*, *Stochastic Pooling* e *Spatial Pyramid Pooling* (GHOLAMALINEZHAD; KHOSRAVI, 2020).

2.4 Modelos de Detecção *Single-Stage*

No domínio da visão computacional, os modelos *single-stage* para detecção de objetos representam uma abordagem que integra a localização e classificação de objetos em uma única passagem de uma rede neural. Em contraste com os modelos de dois estágios, que empregam uma fase inicial de proposição de regiões seguida por uma fase de classificação, os detectores de estágio único executam ambas as tarefas simultaneamente. Estas arquiteturas possuem menos estágios no processo, tornando-as particularmente adequadas para aplicações que demandam processamento em tempo real. As seções a seguir contemplam dois modelos *single-stage* canônicos para detecção de objetos (REDMON et al., 2016).

2.4.1 YOLO

A detecção de objetos em tempo real tornou-se essencial em aplicações como veículos autônomos, robótica, videomonitoramento e realidade aumentada. Entre os algoritmos propostos, a família YOLO (*You Only Look Once*) destaca-se pelo equilíbrio entre velocidade e precisão. Introduzido por Redmon et al. na CVPR 2016 (REDMON et al., 2016), o YOLO realiza a detecção com uma única passagem pela rede, ao contrário de abordagens anteriores baseadas em janelas deslizantes ou arquiteturas em duas etapas, como as RCNNs. Sua arquitetura unificada utiliza apenas regressão para prever classes e coordenadas das caixas delimitadoras, diferindo de métodos como o Fast R-CNN (GIRSHICK, 2015), que empregam saídas separadas para classificação e regressão (TERVEN; CórDOVA-ESPARZA; ROMERO-GONZÁLEZ, 2023).

A figura 2.7 representa o sistema YOLO que modela a detecção como um

problema de regressão direto, mapeando de forma conjunta as localizações dos objetos e suas respectivas classes. Para isso, a imagem de entrada é dividida em uma grade de tamanho $S \times S$. Cada célula dessa grade é responsável por prever B caixas delimitadoras (*bounding boxes*), juntamente com um escore de confiança para cada uma delas, além das probabilidades associadas às C classes possíveis. Essas saídas são codificadas como um tensor de dimensão $S \times S \times (B \cdot 5 + C)$, onde cada conjunto de 5 valores representa as coordenadas da caixa e o grau de confiança da detecção (REDMON et al., 2016).




Figura 2.7: Esquema de detecção do YOLO (REDMON et al., 2016).

Redmon et al., em 2016, unificaram os componentes separados da detecção de objetos em uma única rede neural. A rede usa características de toda a imagem para prever cada caixa delimitadora e todas as caixas delimitadoras em todas as classes simultaneamente, permitindo um raciocínio global sobre a imagem e todos os objetos. O design do YOLO permite treinamento completo e alta velocidade

em tempo real, mantendo alta precisão média. A imagem de entrada é dividida em uma grade, onde cada célula é responsável por detectar um objeto cujo centro caia nela. Cada célula prevê caixas delimitadoras e pontuações de confiança, refletindo a certeza do modelo de que a caixa contém um objeto e a precisão da previsão. Formalmente, a confiança é definida como a probabilidade de um objeto existir na célula multiplicada pela IOU (Intersection Over Union) entre a caixa prevista e a verdade fundamental. Se não houver objeto, a pontuação de confiança é zero. Cada caixa delimitadora tem 5 previsões: coordenadas do centro (x,y), largura e altura em relação à imagem inteira e IOU entre a caixa prevista e qualquer caixa de verdade fundamental. Cada célula também prevê probabilidades de classe condicionais, indicando a probabilidade de uma classe aparecer na caixa, dado que há um objeto. Prevemos apenas um conjunto de probabilidades por célula, independentemente do número de caixas. No teste, multiplicamos as probabilidades de classe condicionais e as previsões de confiança individuais, obtendo pontuações de confiança específicas de classe para cada caixa, codificando a probabilidade da classe e a precisão da caixa (REDMON et al., 2016).

A Figura 2.8 apresenta a arquitetura original do modelo YOLO é composta por 24 camadas convolucionais seguidas por 2 camadas totalmente conectadas. O uso de convoluções 1×1 intercala as camadas principais, com o objetivo de reduzir a dimensionalidade do espaço de características e otimizar o processamento. As camadas convolucionais foram inicialmente pré-treinadas para classificação na base ImageNet com imagens de 224×224 pixels, e posteriormente a resolução foi dobrada para 448×448 com o intuito de adaptar a rede para a tarefa de detecção de objetos (REDMON et al., 2016).

Avaliado no conjunto de dados de teste-dev 2017 do MS COCO, o YOLOv5x




Figura 2.8: Arquitetura da rede YOLO para detecção de objetos (REDMON et al., 2016).

alcançou uma Precisão Média (AP) de 50,7% com imagens de 640 pixels. Com um tamanho de lote de 32, ele pode alcançar uma velocidade de 200 quadros por segundo (FPS) em uma placa NVIDIA V100. Ao usar um tamanho de entrada maior de 1536 pixels e técnicas de aumento no tempo de teste (TTA), o YOLOv5 alcança uma AP de 55,8%. A arquitetura reduzida foi chamada de YOLOv4-tiny; ela foi projetada para GPUs de baixo desempenho e pode rodar a 46 FPS em um Jetson TX2 ou 440 FPS em um RTX2080Ti, alcançando 22% de AP no MSCOCO. A arquitetura do modelo ampliado foi chamada de YOLOv4-large, que incluía três tamanhos diferentes: P5, P6 e P7. Esta arquitetura foi projetada para GPU em nuvem e alcançou desempenho de ponta, superando todos os modelos anteriores [6, 7, 89] com 56% de AP no MSCOCO. Os autores fornecem oito modelos em escala, de YOLOv6-N a YOLOv6-L6. Avaliados no conjunto de dados de teste-dev 2017 do MS COCO, o maior modelo alcançou um AP de 57,2% a cerca de 29 FPS em uma NVIDIA Tesla T4. Avaliado no conjunto de dados de teste-dev MS COCO 2017, o YOLOv7-E6 alcançou um AP de 55,9% e AP_{50} de 73,5% com um tamanho de entrada de 1280 pixels com uma velocidade de 50 FPS em

uma NVIDIA V100. Avaliado no conjunto de dados de teste-dev 2017 do MS COCO, o YOLOv8x alcançou um AP de 53,9% com um tamanho de imagem de 640 pixels (comparado a 50,7% do YOLOv5 no mesmo tamanho de entrada) com uma velocidade de 280 FPS (quadros por segundo) em uma GPU NVIDIA A100 e TensorRT (TERVEN; Córdova-Esparza; Romero-González, 2023).

Modelos do tipo *single-stage*, como os da família YOLO, têm sido amplamente adotados em tarefas biomédicas que exigem detecção em tempo real com baixo custo computacional. Estudos recentes demonstram que versões mais enxutas e modernas da arquitetura, como a YOLOv4-tiny, YOLOv5 e YOLOv7, são capazes de realizar detecção de estruturas microscópicas, como ovos de parasitas intestinais, com alta acurácia e eficiência computacional significativamente superior a modelos tradicionais mais pesados. Essa constatação reforça o potencial de aplicabilidade das versões recentes da YOLO em contextos similares, como a detecção de parasitas da malária em lâminas de gota espessa (Venkatesan et al., 2025).

2.4.2 *Single-Shot Detectors (SSD)*

Liu et al. introduziram uma nova abordagem para a detecção de objetos em imagens, utilizando uma única rede neural profunda. Ao contrário dos métodos tradicionais que dependem da geração de propostas de caixas delimitadoras e da reamostragem de pixels ou características, o SSD discretiza o espaço de saída das caixas delimitadoras, dividindo-o em um conjunto de caixas padrão com diferentes relações de aspecto e escalas em cada posição do mapa de características. Essa abordagem inovadora permite que o SSD preveja, em tempo de execução, tanto a presença de cada categoria de objeto em cada caixa padrão quanto os ajustes

necessários para que a caixa se adapte à forma do objeto. Uma das principais vantagens do SSD reside na sua simplicidade em comparação com outros métodos que exigem propostas de objetos. Ao eliminar a necessidade de gerar propostas e realizar a reamostragem de pixels ou características, o SSD encapsula todo o processo computacional em uma única rede neural. Essa arquitetura simplificada não apenas facilita o treinamento do modelo, mas também o torna mais rápido e fácil de integrar em sistemas que requerem um componente de detecção de objetos. Além disso, o SSD se destaca pela sua capacidade de realizar detecções em múltiplas escalas, utilizando mapas de características de diferentes camadas da rede neural. Essa característica permite que o modelo lide com objetos de diversos tamanhos de forma eficiente, tornando-o uma ferramenta poderosa para a detecção de objetos em tempo real (LIU et al., 2016).

O SSD adiciona camadas de características convolucionais ao final da rede base. Essas camadas diminuem progressivamente em tamanho e permitem a previsão de detecções em múltiplas escalas. A ideia central é que cada camada da rede neural, por ter diferentes resoluções, pode ser responsável por detectar objetos de tamanhos específicos. As camadas mais profundas, com menor resolução, são responsáveis por detectar objetos maiores, enquanto as camadas mais rasas, com maior resolução, focam em objetos menores. Essa abordagem permite que o SSD seja mais eficaz na detecção de objetos de diferentes tamanhos em uma única imagem. O modelo convolucional para prever detecções é diferente para cada camada de características, comparando ao YOLO que trabalha com apenas uma escala no mapa de características. Preditores Convolucionais para Detecção: Cada camada de características adicionada (ou opcionalmente uma camada existente da rede base) pode produzir um conjunto fixo de previsões de detecção

usando filtros convolucionais. Estes são indicados no topo da arquitetura de rede *SSD* na Fig. 9. Para uma camada de características de tamanho $m \times n$ com p canais, o elemento básico para prever parâmetros de uma detecção potencial é um pequeno kernel $3 \times 3 \times p$ que produz ou uma pontuação para uma categoria, ou um deslocamento de forma em relação às coordenadas da caixa padrão. Em cada um dos $m \times n$ locais onde o kernel é aplicado, ele produz um valor de saída. Os valores de saída do deslocamento da caixa delimitadora são medidos em relação a uma posição padrão da caixa em relação a cada local do mapa de características. Em comparação, YOLO usa uma camada intermediária totalmente conectada em vez de um filtro convolucional para esta etapa. *SSD* usa uma abordagem de Caixas Padrão e Proporções na qual cada célula dos mapas de características, em diferentes níveis da rede, recebe um conjunto de caixas delimitadoras padrão. Essas caixas cobrem o mapa de forma que sua posição relativa à célula seja fixa. Para cada caixa, prevemos deslocamentos em relação à forma padrão e pontuações por classe, indicando a presença de objetos. Calculamos c pontuações e 4 deslocamentos por caixa, resultando em $(c + 4)k$ filtros por local e $(c + 4)kmn$ saídas para um mapa $m \times n$. Nossas caixas padrão, semelhantes às âncoras do Faster R-CNN, são aplicadas a vários mapas de diferentes resoluções, permitindo discretizar o espaço de possíveis formas de saída. (LIU et al., 2016).

Para a maioria dos detectores de objetos baseados em mapas de características multiescala, as camadas superficiais são ricas em informações espaciais finas e, portanto, são as principais responsáveis pela detecção de pequenos objetos. Para Lisha Cui, o desempenho da detecção de objetos pequenos, entretanto, ainda é menos que satisfatório devido à deficiência de informação semântica em mapas de características superficiais. Para contornar a problemática a autora introduz




Figura 2.9: Uma comparação entre dois modelos de detecção de disparo único (*single shot*): SSD e YOLO (REDMON et al., 2016). Nosso modelo SSD adiciona várias camadas de recursos ao final de uma rede base, que preveem os deslocamentos para caixas padrão de diferentes escalas e relações de aspecto, bem como suas respectivas confianças. O SSD com tamanho de entrada de 300×300 supera significativamente seu equivalente YOLO de 448×448 em precisão no teste VOC2007, além de melhorar a velocidade de execução, embora a rede personalizada do YOLO seja mais rápida que o VGG16 (LIU et al., 2016).

ziu *Deconvolucional de Disparo Único Multiescala (MDSSD)*, na qual a estrutura proposta atinge 77,6% de mAP para detecção de pequenos objetos no desafiador conjunto de dados TT100K com entrada de 512×512 (CUI, 2018). Na literatura temos também o detector de disparo único baseado em fusão de recursos e escalonamento (FS-SSD) para detecção de pequenos objetos nas imagens de veículos aéreos não tripulados com mAP de 64,19%, comparado com o modelo SSD padrão que resultou um mAP de 60,33% (LIANG et al., 2020). Ming Li introduziu detector eficiente de disparo único com fusão de recursos baseada em peso (*WFFA-SSD*) que aumenta o mAP do carro em 4,12% no conjunto de testes do CARPK (LI;

PI; QIN, 2023).

O *DSSD (Deconvolutional Single Shot Detector)* é uma rede neural convolucional para detecção de objetos que melhora o SSD (Single Shot MultiBox Detector) ao adicionar camadas de deconvolução e conexões de salto para incorporar contexto de larga escala e melhorar a detecção de objetos pequenos. Ao usar a rede Residual-101 como base e um módulo de predição aprimorado, o DSSD alcançou resultados de ponta em conjuntos de dados PASCAL VOC 2007 (81,5 % mAP), PASCAL VOC 2012 (80,0 % mAP) e COCO (33,2 % mAP), superando métodos como *R-FCN*. O DSSD se destaca na detecção de objetos pequenos e em classes com contexto específico, como aviões e vacas, demonstrando a eficácia da incorporação de contexto na detecção de objetos.

FSSD (Feature Fusion Single Shot Multibox Detector) é um detector de objetos de estágio único que prioriza a velocidade de inferência. Ele utiliza uma pirâmide de características para detectar objetos em diferentes escalas, mas, ao contrário do SSD, não funde características de diferentes camadas da rede neural. FSSD300, um modelo FSSD com tamanho de entrada 300×300 , atinge uma precisão média (mAP) de 78,8 % no conjunto de testes *PASCAL VOC2007*, enquanto SSD300 atinge 77,2 % mAP. No conjunto de testes *MS COCO*, FSSD300 atinge 27,1 % mAP, superando SSD300 (25,1 %). FSSD512 supera SSD512 em ambos os conjuntos de dados. No entanto, FSSD é mais lento que SSD devido à sua arquitetura mais complexa (LI; YANG; ZHOU, 2024).

O RefineDet, um detector de objetos de duas etapas, utiliza uma rede neural convolucional profunda para gerar propostas de regiões e classificá-las. No entanto, ele se destaca pela baixa precisão, especialmente na detecção de objetos pequenos. Em experimentos no conjunto de dados PASCAL VOC 2007, o RefineDet320 ob-

teve um mAP de 80,0 %, ficando atrás de outros detectores de uma etapa, como o RFBNet300, que atingiu 80,5 % de mAP. Além disso, o desempenho do Refine-Det na detecção de objetos pequenos no conjunto de dados MS COCO também é inferior a outros métodos de ponta como o próprio SSD (LI; LIU, 2019).

M2Det é um detector de objetos de estágio único (one-stage) que se destaca pela sua *Multi-Level Feature Pyramid Network* (MLFPN). Essa arquitetura inovadora combina características de diferentes níveis e escalas para melhorar a detecção de objetos em diversas escalas e com variações de aparência. Ao integrar a MLFPN à arquitetura do SSD, o M2Det alcança resultados *state-of-the-art*, superando outros detectores de estágio único. Especificamente, no *benchmark* MS COCO, o M2Det atinge um AP de 41,0 com uma velocidade de 11,8 FPS em inferência de escala única e um AP de 44,2 com inferência em múltiplas escalas (ZHAO et al., 2019).

2.5 Trabalhos Relacionados

A análise automatizada de imagens microscópicas é uma ferramenta valiosa para subsidiar os profissionais em suas atividades para realização do diagnóstico considerando que o proposto decorre do padrão-ouro, na literatura temos trabalhos como de Guimarães e Guedes que trás o uso de redes neurais convolucionais (CNNs) e técnicas de aprendizado de máquina, especificamente a transferência de aprendizado que dá subsídio no aprimoramento de performance de *baseline* das CNNs na tarefa-alvo, para automatizar a classificação binária de imagens microscópicas de células sanguíneas humanas em *infectadas* ou *não infectadas*. A pesquisa avaliou diferentes arquiteturas de CNNs pré-treinadas, incluindo VGG-16, InceptionV3, ResNet-50 e EfficientNetB0, em termos de métricas como acurácia, precisão, re-

vocação e F1-Score. Os resultados destacaram a arquitetura EfficientNetB0 como a mais eficaz na classificação de imagens de células sanguíneas para o diagnóstico da malária, com potencial para auxiliar no tratamento precoce da doença. Os pesquisadores trabalharam com um conjunto de 27.588 exemplos rotulados de células sanguíneas humanas, obtidas a partir do pré-processamento com algoritmos de detecção e segmentação (GUIMARÃES, 2022).

O trabalho de Albuquerque e Guedes toma uma abordagem com YOLO para a detecção em imagens sem precisar de uma etapa de pré-processamento com algoritmos de detecção e segmentação. O conjunto de dados utilizado neste estudo é proveniente de um hospital universitário em Bangladesh, abrangendo 150 pacientes e 1830 imagens de lâminas de sangue. As imagens, capturadas por um microscópio acoplado a uma câmera de celular, apresentam resolução de 4032×3024 pixels. As informações sobre as células brancas do sangue foram excluídas, pois não eram relevantes para o escopo da pesquisa. No total, havia 84.509 anotações para a classe de interesse (protozoários da malária) nos exemplos do conjunto de dados. O melhor modelo pela métrica *F-Score* com valor de 80,58 % foi o *YOLOv5* versão *Small* e pela métrica mAP@50 com valor de 81,4 % foi o modelo *YOLOv7* versão *X* (ALBUQUERQUE; GUEDES, 2023).

No trabalho de Araújo e Costa, o conjunto de dados utilizado neste estudo, nomeado *BBBC041v1*, é composto por 1328 imagens microscópicas de esfregaço de gota espessa de sangue de pacientes com suspeita de malária por *Plasmodium vivax*. Dessas imagens, foram extraídas cerca de 80.000 subimagens de células, cada uma rotulada como saudável (glóbulos vermelhos ou leucócitos), infectada (anel, gametócito, esquizonte, trofozoíto) ou difícil de rotular. O conjunto de dados apresenta um desequilíbrio de classes, com cerca de 95 % das células sendo

saudáveis. Para balancear as classes, foram utilizadas técnicas de subamostragem e ponderação da taxa de aprendizado. O desempenho dos modelos de classificação *EfficientNet B7* foi avaliado com as métricas de acurácia, precisão, sensibilidade, especificidade e F1-score. O melhor modelo obteve uma acurácia de 89,91 % e um F1-score de 83,88 % (ARAUJO, 2023).

O estudo de Nascimento utilizou um conjunto de dados de 1819 imagens de lâminas de esfregaço de sangue de 150 pacientes infectados com *P. falciparum*, coletadas no Chittagong Medical College Hospital, em Bangladesh. As imagens foram capturadas com uma câmera de smartphone acoplada a um microscópio com ampliação de $100\times$, resultando em imagens RGB de 3024×4032 pixels. Um especialista anotou manualmente 84.961 parasitas nas imagens, com raios variando de 2 a 96 pixels. As técnicas apresentadas neste trabalho se baseiam em redes como perceptron simples, multicamadas e regressor logístico associados a técnicas como segmentação através do método de Otsu e morfologia matemática. O estudo explorou três arquiteturas de redes neurais rasas: perceptron simples, regressor logístico e perceptron multicamadas. O perceptron multicamadas, com duas camadas ocultas de 15 neurônios cada, apresentou o melhor desempenho, alcançando uma precisão de 96,33 % , sensibilidade de 98,85 % e F1-score de 97,57 %. Em termos de complexidade computacional, o método com perceptron simples levou 1,18 segundos para analisar uma lâmina, enquanto o regressor logístico e o perceptron multicamadas levaram 1,2 segundos e 3,29 segundos, respectivamente (NASCIMENTO, 2023).

A lacuna na literatura em relação à aplicação de modelos SSD para a detecção de malária em imagens microscópicas representa uma oportunidade de pesquisa promissora. Modelos SSD e da família YOLO, são conhecidos por sua velocidade e

eficiência, características cruciais para o desenvolvimento de ferramentas de diagnóstico rápido e acessível. O trabalho de Albuquerque demonstrou a viabilidade da aplicação de modelos da família YOLO, como YOLOv5 e YOLOv7, na detecção de malária, alcançando resultados promissores em métricas como F-Score e mAP@50 (ALBUQUERQUE; GUEDES, 2023).

A Tabela 2.1 apresenta um resumo dos principais trabalhos relacionados utilizando *CNNs* para classificação ou detecção de malária em imagens microscópicas. As abordagens variam em termos de tarefa, volume de dados e modelos empregados. Observa-se que a maioria dos trabalhos realiza classificação, com destaque para as arquiteturas EfficientNet B0 e B7 (GUIMARÃES, 2022; ARAUJO, 2023), além do uso de redes neurais rasas como no trabalho de (NASCIMENTO, 2023).

Entre os trabalhos de detecção, destaca-se (ALBUQUERQUE; GUEDES, 2023), que utiliza a base Thick_Smears_150 com mais de 84 mil anotações e o modelo YOLOv7x. O trabalho proposto também realiza detecção, porém com a base BBBC041v1, anteriormente usada por (ARAUJO, 2023) para classificação. Com isso, propõe-se uma nova aplicação para essa base, agora explorando um detector mais leve, o YOLOv12n, adequado para cenários com restrição de recursos computacionais.

Tabela 2.1: Comparação entre trabalhos relacionados

Trabalho	Base de Dados	Tipo de Tarefa	Modelo de Referência
(GUIMARÃES, 2022)	27588 anotações	Classificação	EfficientNet B0
(ALBUQUERQUE; GUEDES, 2023)	Thick_Smears_150 (1830 imagens e 84509 anotações)	Detecção	YOLOv7x
(ARAUJO, 2023)	BBBC041v1 (1328 imagens e 2452 anotações)	Classificação	EfficientNet B7
(NASCIMENTO, 2023)	1819 imagens com 84961 anotações	Classificação	Perceptron Multicamadas
Trabalho Proposto	BBBC041v1	Detecção	YOLOv12n

Capítulo 3

Materiais e Métodos

Este estudo investigou a aplicação da Visão Computacional na identificação automática de protozoários responsáveis pela malária em imagens microscópicas de esfregaços sanguíneos. A pesquisa se concentrou na detecção de objetos de classe única, utilizando o paradigma de Aprendizado Supervisionado com YOLO e SSDs. Para construir a solução proposta, a Seção 3.1 detalha os dados experimentais empregados na coleta de conhecimento; a Seção 3.2 apresenta o modelo SSD; e a Seção 3.3 descreve a obtenção das métricas de desempenho.

3.1 Dados Experimentais: Análise Exploratória e Preparação Experimental

O conjunto já citado no trabalho de Araújo e Costa é conhecido como BBBC041 e consiste em 1328 imagens de células sanguíneas infectadas com malária, coletadas por três pesquisadores distintos. Este conjunto é particularmente valioso para o desenvolvimento de métodos automáticos de contagem e classificação de células

infectadas e devido à sua curadoria rigorosa e à diversidade de exemplos (ARAÚJO, 2023).

A fim de conduzir uma análise sobre o conjuntos de dados BBBC041, a Tabela 3.1 apresenta a quantidade de imagens, o número total de caixas delimitadoras, a média e o desvio padrão da quantidade de caixas delimitadoras por quantidade total de imagem, além da incidência mínima e máxima de caixas delimitadoras por imagem. O conjunto é dividido em dois subconjuntos em suas anotações, o subconjunto de treino e de teste.

Tabela 3.1: Descrição estatística das quantidades de imagens e *caixas delimitadoras* nas bases de dados selecionadas.

	Qtd Imagens	Qtd caixas delimitadoras	Média e Desvio Padrão	Mín	Máx
Conjunto de Treino	1208	2149	2.42 ± 1.78	1	11
Conjunto de Teste	120	303	2.63 ± 1.50	1	8

A Figura 4.2 ilustra amostras dos conjuntos de dados e proporciona uma compreensão da distribuição de *caixas delimitadoras* nas imagens, representando o conjunto de dados, exhibe exemplos de imagens com quantidades mínima, mediana e máxima de caixas delimitadoras, evidenciando a variabilidade na concentração de objetos. Essa análise visual é fundamental para entender a complexidade das tarefas de detecção de objetos.

A distribuição da frequência de imagens por faixa de quantidade de caixas delimitadoras é ilustrada nos histogramas das Figuras 3.2 e 3.3, correspondentes aos conjuntos de treino e teste, respectivamente. Observa-se em ambos os casos uma distribuição assimétrica com curtose positiva, indicando concentração acentuada de imagens com poucas instâncias por quadro. Esse padrão revela que a maioria das amostras representa situações visuais pouco complexas, com apenas um ou




Figura 3.1: Comparação de imagens com diferentes quantidades de caixas delimitadoras do conjunto de dados.

dois objetos por imagem. Por outro lado, há uma escassez significativa de exemplos com maior densidade de objetos, o que pode comprometer o desempenho do modelo em cenários mais desafiadores. Essa limitação estrutural do conjunto de dados reforça a importância de estratégias de balanceamento ou geração sintética de exemplos para promover uma cobertura mais representativa da variabilidade presente em aplicações reais.

As dimensões das caixas delimitadoras estão descritas na Tabela 3.2, por meio das métricas estatísticas de média e desvio padrão. Também foi elucidado o menor e o maior valor de ocorrência de cada dimensão.

Tabela 3.2: Descrição estatística das *dimensões* das *caixas delimitadoras* normalizadas pelas dimensões das imagens

	Largura			Comprimento		
	Média e Desvio Padrão	Mín	Máx	Média e Desvio Padrão	Mín	Máx
Treino	132.22 ± 22.07	58	231	132.95 ± 23.55	63	255
Teste	160.15 ± 25.16	82	296	146.70 ± 21.82	82	228




Figura 3.2: Histograma da quantidade de *caixas delimitadoras* por imagens do conjunto de Treino




Figura 3.3: Histograma da quantidade de *caixas delimitadoras* por imagens do conjunto de Teste

A análise da distribuição de tamanho de área das caixas delimitadoras, através de histogramas de Distribuição das áreas das caixas delimitadoras proporciona uma visão crucial sobre a natureza dos conjuntos de exemplos em tarefas de visão computacional. Essa ferramenta estatística permite identificar padrões de ocorrência, como a predominância de objetos grandes ou pequenos, a variabilidade de

tamanhos e a existência de outliers. Ao segmentar as áreas em faixas e contabilizar a frequência de caixas delimitadoras em cada uma, é possível visualizar graficamente a densidade de caixas em diferentes intervalos de área, revelando nuances importantes sobre a composição dos dados. Nas Figuras 3.4 e 3.5 observa-se a distribuição das caixas delimitadoras por área dos conjuntos de dados.




Figura 3.4: Histograma da quantidade de *caixas delimitadoras* por Faixa de área do conjunto de treino

3.2 Modelos e Parametrização

Neste trabalho, foram avaliados seis modelos de detecção de objetos aplicados à tarefa de identificação de parasitas da malária em imagens microscópicas da gota espessa. Os modelos utilizados abrangem uma arquitetura do tipo SSD e cinco variantes da família YOLOv12, selecionadas por sua relevância na literatura e delimitação como single-stage.

O modelo SSD adotado baseia-se na proposta original de Liu et al. (2016) e




Figura 3.5: Histograma da quantidade de *caixas delimitadoras* por faixa de área do conjunto de teste

utiliza como rede base uma VGG-16. Essa arquitetura inclui camadas adicionais convolucionais específicas para detecção, operando com imagens de entrada no formato $300 \times 300 \times 3$. As caixas delimitadoras âncoras foram configuradas com base nas proporções adotadas no conjunto VOC2007, sendo atribuídas por camada preditora. A estrutura do modelo inclui normalização L2, camadas convolucionais com ativação ReLU, cabeças de predição para classes e coordenadas, bem como camadas de pós-processamento responsáveis por suprimir sobreposições redundantes via NMS (Non-Maximum Suppression). O treinamento foi conduzido com taxa de aprendizado inicial de 5×10^{-5} , utilizando o critério de parada antecipada com paciência de 50 épocas e número máximo de 1000 épocas. O limiar de confiança foi fixado em 0,1 e o IoU para supressão não máxima em 0,45. O modelo contém 37.247.650 parâmetros totais, dos quais 37.208.930 são treináveis. Adicionalmente, o modelo foi adaptado para integrar o uso de *triplet loss* como função auxiliar durante o treinamento, mantendo compatibilidade com a lógica de predição original.

Tal adaptação foi motivada pelo fato de tratar-se de um problema de classe única, onde a *triplet loss* permite explorar relações estruturais entre amostras positivas e negativas a partir da distância no espaço latente. Essa abordagem visa mitigar problemas de mínimos locais e fornecer uma métrica adicional para acompanhamento do treinamento, permitindo observar de forma separada os erros de classificação, regressão e estrutura representacional.

As variantes da arquitetura YOLOv12 foram exploradas com o intuito de estabelecer comparações sistemáticas entre diferentes níveis de capacidade computacional. A versão YOLOv12n (*nano*) representa a configuração mais leve da família, com arquitetura extremamente compacta e 2.508.539 parâmetros. Em seguida, a versão YOLOv12s (*small*) oferece uma estrutura ligeiramente mais profunda e densa, totalizando 9.074.595 parâmetros. O modelo YOLOv12m (*medium*) incorpora maior profundidade e número de filtros por camada, atingindo 19.577.299 parâmetros. Já a variante YOLOv12l (*large*) expande ainda mais a estrutura da rede, com blocos convolucionais adicionais e um total de 26.394.323 parâmetros. Por fim, o modelo YOLOv12x (*extra-large*) representa a configuração mais robusta, com arquitetura densa e profunda, composta por 59.246.035 parâmetros.

Todos os modelos YOLOv12 foram utilizados com suas configurações arquiteturais originais, permitindo comparações consistentes sob condições experimentais controladas. O conjunto de modelos testados reflete uma variação intencional de profundidade e custo computacional, visando avaliar o impacto dessas escolhas arquitetônicas na tarefa de detecção automatizada de parasitas da malária.

3.3 Avaliação de Desempenho

Para a avaliação de desempenho dos modelos, foi utilizada a técnica de validação cruzada do tipo *holdout*, com divisão estratificada realizada automaticamente pela plataforma Roboflow. A base de dados final é composta por 1003 imagens anotadas, provenientes de amostras de esfregaço de sangue com coloração Giemsa. As imagens foram divididas em três subconjuntos: 809 imagens (81 %) foram destinadas ao treinamento, 79 imagens (8 %) compuseram o conjunto de validação, e 115 imagens (11 %) formaram o conjunto de teste. Todas as imagens foram redimensionadas para 640×640 pixels, com preservação da proporção por estiramento (*resize stretch*), e tiveram orientação automática aplicada (*auto-orient*). Nenhuma técnica de aumento de dados (*data augmentation*) foi aplicada nesta versão do conjunto. As anotações seguem o formato YOLO e Pascal VOC, com coordenadas de caixas delimitadoras para a classe “parasita”, única presente na base.

Na aferição de soluções para detecção de objetos são contempladas múltiplas métricas as quais avaliam a qualidade da localização e também da classificação. A apresentação das métricas a seguir é baseada em um *survey* disponível na literatura (PADILLA; NETTO; SILVA, 2020). A primeira métrica considerada é a *Intersection Over Union* (IoU), a qual afere a sobreposição entre uma caixa delimitadora prevista B_p e a caixa delimitadora desejada B_d , calculada como segue:

$$\text{IoU} = \frac{\text{area}(B_p \cap B_d)}{\text{area}(B_p \cup B_d)}. \quad (3.1)$$

Ao comparar o IoU com um *threshold* t , tem-se que quando $\text{IoU} \geq t$ a detecção é correta, e incorreta em caso contrário. Esta métrica varia no intervalo $[0, 1]$, alcançando o valor máximo quando a sobreposição das áreas é perfeita (MICHELUCCI,

2019). A partir do IoU é possível então ter três tipos de resultados:

- **Verdadeiro Positivo (TP, do inglês *True Positive*)**. Detecção correta de uma *bouding box* desejada;
- **Falso Positivo (FP, do inglês *False Positive*)**. Uma detecção incorreta de um objeto inexistente ou uma detecção mal posicionada de um objeto existente;
- **Falso Negativo (FN, do inglês *False Negative*)**. A não detecção de uma *bouding box* desejada.

A partir da quantificação dos valores dos três tipos de resultados, calculam-se então as métricas de Precisão (P) e Revocação (R), dadas como segue:

$$P = \frac{TP}{TP + FP}, \quad (3.2) \quad R = \frac{TP}{TP + FN}. \quad (3.3)$$

A precisão e a revocação costumam ser sintetizadas em uma única métrica denominada F_1 -Score, a qual contempla a média harmônica dos dois valores previamente mencionados, calculada como segue:

$$F_1\text{-Score} = \frac{2 \times P \times R}{P + R}. \quad (3.4)$$

A curva da precisão *versus* revocação, denominada curva ROC, pode ser compreendida como o balanço entre a precisão e a revocação associadas às *caixas delimitadoras* geradas por um detector. Um detector de objetos é considerado bom quando a precisão se mantém alta à medida que a revocação aumenta, o que significa que, à medida que o limiar de confiança varia, tanto a precisão quanto a revocação se mantêm altas. Assim, a área sob a curva ROC (AUC ROC) tende a refletir tais características de um detector.

Em muitas situações, porém, a curva ROC possui um formato serrilhado, o que dificulta o cálculo do AUC ROC. Para contornar esta dificuldade, tem-se a métrica *Average Precision* (AP) que é obtida a partir da média dos valores de uma interpolação de 11 pontos igualmente distribuídos na $(\{0, 0.1, \dots, 0.9, 1\})$ para diferentes níveis de revocação, calculada como segue:

$$AP = \frac{1}{11} \sum_{R \in \{0, 0.1, \dots, 0.9, 1\}} P_{\text{interp}}(R), \quad (3.5)$$

em que $P_{\text{interp}}(R) = \max_{\tilde{R}: \tilde{R} > R} P(\tilde{R})$. A média da AP (mAP, do inglês *Mean Average Precision*) denota a média aritmética ponderada do AP de todas as classes presentes:

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i, \quad (3.6)$$

em que AP_i denota o valor do AP da i -ésima classe e N é o número total de classes. O AP e o mAP são amplamente utilizadas na avaliação de sistemas de detecção de objetos, inclusive tendo sido adotados em competições relevantes da área, tais como o *Open Image Dataset*, *Pascal VOC Challenge* e *MS COCO Challenge* (KUZNETSOVA et al., 2020; EVERINGHAM et al., 2010).

3.4 Tecnologias Utilizadas

O desenvolvimento deste trabalho foi conduzido com o uso de ferramentas consolidadas no campo da visão computacional e do aprendizado profundo, com ênfase em ambientes de execução compatíveis com aceleração por GPU. A linguagem de programação adotada foi o Python, devido à sua ampla aceitação na comunidade

científica, sintaxe acessível e integração madura com bibliotecas otimizadas para ciência de dados e modelagem de redes neurais profundas.

Para a implementação dos modelos, foi utilizado o framework PyTorch, na versão 2.6.0, aproveitando os avanços da geração mais recente em suporte a dispositivos CUDA (com compatibilidade explícita com o ecossistema cu12) e ferramentas como o compilador de kernels `triton`. A biblioteca `torchvision` (0.21.0) foi empregada para a construção dos *dataloaders*, transformações visuais e modelos pré-treinados. No pré-processamento das imagens, utilizaram-se as bibliotecas `albumentations` (2.0.5), `pillow`, `opencv-python` e `numpy`, aplicando transformações como redimensionamento, normalização, reorganização de canais e rotação. O modelo SSD300 (Single Shot MultiBox Detector) foi configurado com arquitetura customizada em PyTorch, com modificações na *head* de detecção e na função de perda.

Em paralelo, foram treinados modelos da família YOLOv12, utilizando uma implementação moderna hospedada no repositório Git da Ultralytics (`ultralytics@yolov12.git`), com suporte à exportação para ambientes edge e extensível para análise avançada de métricas. O treinamento de todos os modelos foi realizado com aceleração CUDA e gerenciamento explícito de memória, otimizando o tempo de convergência e viabilizando experimentos em lote.

Durante os experimentos, a avaliação quantitativa dos modelos e a análise de métricas foram realizadas com suporte das bibliotecas `torchmetrics` (1.7.1) e `scikit-learn` (1.6.1). A análise estatística, geração de gráficos e organização tabular dos resultados foram conduzidas com o auxílio das bibliotecas `pandas` (2.2.3), `matplotlib` (3.10.1) e `seaborn` (0.13.2). O rastreamento dos experimentos foi realizado de forma local, com registro estruturado de hiperparâmetros,

curvas de perda e métricas, permitindo monitoramento em tempo real e posterior análise reprodutível.

Capítulo 4

Resultados e Discussão

Os modelos foram treinados e aferidos com base na divisão do conjunto de dados em treino e validação. Os modelos assumiram um limiar de confiança de 0,5. Os melhores *checkpoints* foram selecionados com base no maior mAP@50 na validação.

Durante o treinamento dos modelos, observou-se a tendência de convergência das curvas de perda nas Figuras 4.1a e 4.2a, indicando que ambos os detectores foram capazes de minimizar seus respectivos erros de forma estável ao longo das épocas. A aplicação do critério de parada antecipada (*early stopping*) foi fundamental para evitar o sobreajuste aos dados de treinamento, interrompendo o processo quando não houve mais melhoria significativa no desempenho da validação segundo a métrica mAP@50 conforme Figuras 4.1b e 4.2b. Este mecanismo reflete um controle efetivo da generalização, permitindo que o modelo mantivesse um bom equilíbrio entre aprendizado e capacidade de previsão sobre dados não vistos. A DFL (do inglês *Distribution Focal Loss*) do modelo SSD300 foi a única métrica que não convergiu, apenas variou em torno da média 7,495 com desvio padrão 0,014, em comparação com Box Loss que variou de 1,623 para 0,061 e teve

redução de aproximadamente 96 % e Class Loss que variou de 4,688 para 0,268 e teve redução de aproximadamente 94 %.




Figura 4.1: Métricas de treino do modelo SSD300.




Figura 4.2: Métricas de treino do modelo YOLOv12 versão nano.

A Tabela 4.1 apresenta uma análise comparativa entre o modelo SSD300 e diferentes variantes do YOLOv12 aplicados à tarefa de detecção de parasitas da malária. As métricas avaliadas incluem mAP@50, mAP@50-95, acurácia, precisão,

revocação, F1-score e número de parâmetros.

O modelo YOLOv12n destacou-se por apresentar o melhor equilíbrio entre eficiência e eficácia. Com apenas 2.508.539 parâmetros, atingiu a maior pontuação de F1-score (0,5991) e a maior precisão (0,8304), além de revocação competitiva (0,4686) e mAP@50 de 0,7470. Esses resultados indicam que o YOLOv12n consegue detectar corretamente a maioria dos parasitas com alta confiabilidade, sendo altamente eficaz mesmo em um regime de baixo custo computacional. Sua elevada precisão com revocação moderada sugere uma abordagem conservadora, com poucas detecções falsas, característica desejável em aplicações médicas.


O SSD300, por outro lado, apresentou um comportamento inverso: alcançou uma revocação extremamente alta (0,9702), porém com precisão mínima (0,0418) e F1-score de apenas 0,0801. Isso implica que, embora quase todos os objetos reais sejam detectados (alta sensibilidade), o modelo gera um número excessivo de falsas detecções, comprometendo sua confiabilidade prática. A baixa acurácia global (0,0418) reforça essa limitação.

Além disso, observa-se que os modelos YOLOv12s e YOLOv12m alcançaram valores intermediários tanto em precisão quanto revocação, mas sem superar a relação custo-benefício obtida pela versão nano. Isso sugere que, para este cenário específico, arquiteturas mais leves não apenas são mais eficientes em termos computacionais, mas também mais eficazes qualitativamente, possivelmente por melhor se ajustarem à distribuição dos dados e ao balanceamento entre classes positivas e negativas.

Portanto, os resultados apontam o YOLOv12n como o modelo mais apropriado para aplicações práticas de detecção de malária em ambientes com recursos limitados, equilibrando desempenho preditivo e complexidade computacional.

Tabela 4.1: Comparação de desempenho entre diferentes variantes do modelo YOLOv12 e SSD na tarefa de detecção de malária.

Modelo	mAP@50	mAP@50-95	Acurácia	Precisão	Revocação	F1-Score	Parâmetros
SSD300	0,6400	0,6400	0,0418	0,0418	0,9702	0,0801	37.247.650
YOLOv12n	0,7470	0,5798	0,4277	0,8304	0,4686	0,5991	2.508.539
YOLOv12s	0,6361	0,4745	0,3868	0,7458	0,4455	0,5588	9.074.595
YOLOv12m	0,7080	0,5517	0,3750	0,8759	0,3960	0,5454	19.577.299
YOLOv12l	0,5947	0,4569	0,1793	0,6941	0,1947	0,3041	26.394.323
YOLOv12x	0,4647	0,3413	0,0675	0,7241	0,0693	0,1275	59.246.035




(a) SSD300 - Exemplo com quantidade mínima de caixas (b) SSD300 - Exemplo com quantidade mediana de caixas (c) SSD300 - Exemplo com quantidade máxima de caixas

Figura 4.3: Detecção SSD300

As Figuras 4.3 e 4.4 ilustram uma análise qualitativa do desempenho dos modelos SSD300 e YOLOv12n na tarefa de detecção de parasitas da malária. Para essa análise, foram selecionadas três imagens do conjunto de teste representando diferentes níveis de concentração de objetos: mínima, mediana e máxima quantidade de caixas delimitadoras no *ground truth*. Essa seleção tem como objetivo cobrir variações de complexidade visual e carga parasitária nas lâminas.

No caso do SSD300, foi adotado um limiar de confiança de 0,6, visando favorecer predições com maior precisão e minimizar falsos positivos. Como pode



(a) YOLOv12n - Exemplo com quantidade mínima de caixas (b) YOLOv12n - Exemplo com quantidade mediana de caixas (c) YOLOv12n - Exemplo com quantidade máxima de caixas

Figura 4.4: Detecção YOLOv12 nano

ser observado nas Figuras 4.3(a)–(c), o modelo demonstra robustez em cenários com menor concentração de objetos, mantendo boa aderência espacial entre as caixas preditas e as anotações de referência. No entanto, conforme a concentração de parasitas aumenta, nota-se uma tendência à omissão de algumas instâncias, o que sugere uma limitação na capacidade do SSD300 em lidar com sobreposição de objetos ou regiões altamente concentradas. A Figura 3.2 reforça essa hipótese ao evidenciar uma menor representatividade de imagens com alta concentração de objetos no conjunto de treino e validação, o que pode restringir o aprendizado de padrões em cenários com grande concentração de caixas delimitadoras.

Nos experimentos realizados, o modelo YOLOv12n foi avaliado utilizando um limiar de confiança mais permissivo, definido em 0,1, com o objetivo de explorar sua capacidade de *recall*. As subfiguras 4.4(a)–(c) revelam que esse modelo apresentou menor número de detecções em imagens com maior concentração, sua performance decai em regiões mais povoadas. Essa sensibilidade atenuada é acompanhada por uma maior variabilidade espacial: duas caixas preditas apresentam baixa sobreposição com o *ground truth* ou localização imprecisa, comprometendo

a precisão geral da detecção.

Do ponto de vista de aprendizado de máquina para detecção de objetos, esses resultados evidenciam o trade-off clássico entre precisão e abrangência (precisão versus *recall*). O SSD300, com sua arquitetura baseada em predições ancoradas por múltiplas escalas e regiões, mostrou-se conservador e mais estável em termos de localização. Por outro lado, o YOLOv12n, herdeiro de melhorias recentes na família YOLO (como *heads* otimizadas e estratégias de distribuição de *loss*) e que apresentou melhor desempenho nas métricas consideradas, demonstrou maior propensão a explorar o espaço visual em busca de predições, mesmo sob risco de erro de localização.

Considerando a análise quantitativa e qualitativa dos resultados experimentais, é possível concluir que o modelo YOLOv12n é a solução de referência identificada para o problema de detecção de malária proposto, pois demonstrou maiores mAP@50 e mAP@50-95 no cenário de avaliação. Além da alta capacidade de detecção perante a tarefa proposta, uma vantagem adicional da YOLOv12n consiste no baixo número de parâmetros totais dentre todas arquiteturas avaliadas, o que colabora para a adoção dessa solução em dispositivos embarcados, o que pode viabilizar a adoção de forma acoplada a aparelhos de microscopia.

Apesar do bom desempenho apresentado pelo modelo YOLOv12n, é importante destacar que os resultados obtidos devem ser interpretados à luz das limitações do conjunto de dados utilizado. Como discutido anteriormente, a distribuição amostral revelou uma predominância de imagens com poucas instâncias por quadro, indicando um viés em direção a casos de baixa complexidade visual. Essa característica pode ter favorecido modelos mais leves e conservadores, como o YOLOv12n, que demonstrou alta precisão mesmo com menor capacidade de representação. No

entanto, esse viés pode mascarar dificuldades que esses modelos teriam em contextos mais densos ou desbalanceados. Modelos como o SSD300, embora tenham apresentado baixa precisão, revelaram elevada sensibilidade, sugerindo que, em um cenário com mais exemplos complexos, seu desempenho relativo poderia ser distinto. Assim, a ausência de uma distribuição mais uniforme de exemplos, em especial aqueles com maior número de objetos por imagem, constitui uma limitação relevante, impactando tanto o processo de treinamento quanto a avaliação da real robustez dos modelos.

Capítulo 5

Considerações Finais

Este trabalho teve como objetivo geral avaliar a eficácia e a eficiência de modelos do tipo *single-stage* na detecção de parasitas da malária em imagens microscópicas de gota espessa. Para isso, foi realizada uma revisão de literatura, a implementação e treinamento de modelos SSD com *triplet loss* e da família YOLOv12 em diferentes variantes, além de uma análise comparativa dos resultados obtidos com base em métricas quantitativas e qualitativas.

A instabilidade observada na *Distribution Focal Loss* (DFL) durante o treinamento do SSD300 decorre de fatores arquiteturais e metodológicos. O modelo, originalmente projetado para regressão contínua via *Smooth L1 Loss* (LIU et al., 2016), apresenta incompatibilidade intrínseca com a abordagem probabilística discreta da DFL. Essa disparidade entre natureza discreta e contínua na distribuição dos dados intermediários gera flutuações persistentes ($\text{média} = 7,495$, $\sigma = 0,014$) devido aos rigorosos requisitos de normalização e calibração exigidos pela DFL na conversão de logits para distribuições válidas, resultando em uma paisagem de otimização complexa propensa a mínimos locais. Embora tal comportamento

não tenha comprometido significativamente o mAP@50 final (64,0%), evidenciando que o modelo mantém funcionalidade operacional, ele revela uma limitação fundamental do SSD300 em tarefas baseadas em distribuições discretas. Soluções futuras devem priorizar adaptações arquiteturais que incorporem mecanismos robustos de normalização e balanceamento de gradientes, para estabilizar a convergência em cenários análogos. Os experimentos demonstraram que o SSD300, apesar de sua concepção clássica e estrutura relativamente leve, apresentou um desempenho fortemente enviesado à revocação. Com taxa de 0,9702, o modelo foi capaz de localizar quase todas as instâncias anotadas, porém à custa de uma precisão extremamente baixa (0,0418), o que resultou em um F1-score insatisfatório. Esse comportamento sugere que o modelo tem forte tendência à superdetecção, tornando-o inadequado para contextos onde falsos positivos geram impacto crítico, como no apoio diagnóstico automatizado.

A análise qualitativa corroborou os resultados quantitativos. O SSD demonstrou capacidade razoável de localização em imagens menos densas, mas foi sensível à superposição de objetos. Já o YOLOv12n, embora mais seletivo e menos propenso a falsos positivos, mostrou alguma dificuldade em cenários com alta concentração de parasitas, indicando margem para melhorias em sensibilidade.

Dentre as possibilidades de aprimoramento, destaca-se a necessidade de empregar estratégias de balanceamento amostral durante o treinamento, como forma de atenuar os efeitos adversos de distribuições desbalanceadas que impactam diretamente o desempenho dos modelos em cenários com maior complexidade visual.

Em síntese, o objetivo do trabalho foi atingido, oferecendo evidências empíricas de que modelos *single-stage* compactos, como o YOLOv12n, podem ser aplicados com eficiência em tarefas críticas de detecção médica, equilibrando desempenho,

tempo de inferência e consumo de recursos.

Referências Bibliográficas

ALBUQUERQUE, J. D. de; GUEDES, E. B. Microscopia automatizada e inteligente com deep learning para detecção de malária. In: *Anais do Simpósio Brasileiro de Automação Inteligente*. Manaus, Amazonas: SBA, 2023.

ANTINORI, S. et al. Biology of human malaria plasmodia including plasmodium knowlesi. *Mediterr. J. Hematol. Infect. Dis.*, Institute of Hematology, Catholic University, v. 4, n. 1, p. e2012013, mar. 2012.

ARAUJO, F. A. S. *Classificação das fases do Plasmodium em imagens do exame de gota espessa para malária*. Monografia (Trabalho de Conclusão de Curso) — Universidade a ser preenchida, Manaus, AM, 2023.

BRASIL. *Manual de Diagnóstico Laboratorial da Malária*. Brasília: Ministério da Saúde, 2009. (Série A. Normas e Manuais Técnicos). 2. ed.

BRASIL. *Guia prático de tratamento da malária no Brasil*. [S.l.]: Ministério da Saúde, 2010. 36 p. Disponível em <https://bvsms.saude.gov.br/bvs/publicacoes/guia_pratico_malaria.pdf>. Acesso em 25 de março de 2026.

BRASIL. *Boletim Epidemiológico – Volume 55 de 18 de janeiro de 2024*. [S.l.]: Ministério da Saúde – Secretaria de Vigilância em Saúde e Meio Ambiente, 2024. Disponível em <<https://www.gov.br/saude/pt-br/centrais-de-conteudo/publicacoes/boletins/epidemiologicos/edicoes/2024/boletim-epidemiologico-volume-55-no-01>>. Acesso em 25 de março de 2026.

CUI, L. MDSSD: multi-scale deconvolutional single shot detector for small objects. *CoRR*, abs/1805.07009, 2018. Disponível em <<https://arxiv.org/abs/1805.07009>>. Acesso em 25 de março de 2026. Disponível em: <<http://arxiv.org/abs/1805.07009>>.

EVERINGHAM, M. et al. The Pascal Visual Object Classes (VOC) challenge. *International journal of computer vision*, Springer, v. 88, n. 2, p. 303–338, 2010.

FARIA, E. *REDES NEURAIIS CONVOLUCIONAIS E MÁQUINAS DE APRENDIZADO EXTREMO APLICADAS AO MERCADO FINANCEIRO BRASILEIRO*. Tese (Ph.D. thesis) — Instituto Alberto Luiz Coimbra de Pós-Graduação e Pesquisa de Engenharia, Rio de Janeiro, 2018. Disponível em <<https://pantheon.ufrj.br/bitstream/11422/11418/1/ElisangelaLopesDeFaria.pdf>>. Acesso em 25 de março de 2026.

FILHO, A. F. F. et al. Performance of an immunochromatography test for vivax malaria in the amazon region, brazil. *Revista de Saúde Pública*, v. 37, n. 3, p. 390–392, Jun. 2003. Disponível em: <<https://www.revistas.usp.br/rsp/article/view/31605>>.

GHOLAMALINEZHAD, H.; KHOSRAVI, H. Pooling methods in deep neural networks, a review. *arXiv preprint arXiv:2009.07485*, 2020.

GIRSHICK, R. Fast R-CNN. In: *2015 IEEE International Conference on Computer Vision (ICCV)*. [S.l.]: IEEE, 2015.

GOMES, A. P. et al. Malária grave por plasmodium falciparum. *Rev. Bras. Ter. Intensiva*, GN1 Genesis Network, v. 23, n. 3, p. 358–369, set. 2011.

GUIMARÃES, F. B. *Estudo de Caso de Transferência de Aprendizado com Redes Neurais Convolucionais para Classificação de Malária*. Dissertação (Monografia (Aperfeiçoamento/Especialização em Pós-Graduação Lato Sensu em Ciência dos Dados)) — Universidade do Estado do Amazonas, 2022.

HAYKIN, S. *Redes Neurais - 2ed.* [S.l.: s.n.], 2001.

KHAN, S. et al. *A Guide to Convolutional Neural Networks for Computer Vision*. [S.l.]: Morgan & Claypool, 2018. (Synthesis Lectures on Computer Vision).

KRENKER, A.; BESTER, J.; KOS, A. Artificial neural networks technology to model and predict plant biology process. In: _____. [S.l.]: InTech, 2011. cap. Introduction to the Artificial Neural Networks. Disponível em <https://www.researchgate.net/profile/Kenji-Suzuki-2/publication/319316102_Artificial_Neural_Networks_-_Methodological_Advances_and_Biomedical_Applications/links/59a42f16aca272a6461bb35e/Artificial-Neural-Networks-Methodological-Advances-and-Biomedical-Applications.pdf#page=15>. Acesso em 25 de março de 2026.

KUZNETSOVA, A. et al. The open images dataset v4. *International Journal of Computer Vision*, Springer, v. 128, n. 7, p. 1956–1981, 2020.

LEUNG, H.; HAYKIN, S. The complex backpropagation algorithm. *IEEE Trans. Signal Process.*, Institute of Electrical and Electronics Engineers (IEEE), v. 39, n. 9, p. 2101–2104, 1991.

LI, M.; PI, D.; QIN, S. An efficient single shot detector with weight-based feature fusion for small object detection. *Sci. Rep.*, v. 13, n. 1, p. 9883, jun. 2023. Disponível em <<https://www.nature.com/articles/s41598-023-36972-x>>. Acesso em 25 de março de 2026.

LI, W.; LIU, G. A single-shot object detector with feature aggregation and enhancement. In: *2019 IEEE International Conference on Image Processing (ICIP)*. [S.l.]: IEEE, 2019.

LI, Z.; YANG, L.; ZHOU, F. *FSSD: Feature Fusion Single Shot Multibox Detector*. 2024. Disponível em <<https://arxiv.org/abs/1712.00960>>. Acesso em 25 de março de 2026.

LIANG, X. et al. Small object detection in unmanned aerial vehicle images using feature fusion and scaling-based single shot detector with spatial context analysis. *IEEE Trans. Circuits Syst. Video Technol.*, Institute of Electrical and Electronics Engineers (IEEE), v. 30, n. 6, p. 1758–1770, jun. 2020.

LIU, W. et al. SSD: Single shot MultiBox detector. In: *Computer Vision – ECCV 2016*. Cham: Springer International Publishing, 2016, (Lecture notes in computer science). p. 21–37.

MICHELUCCI, U. *Advanced applied deep learning: convolutional neural networks and object detection*. [S.l.]: Springer, 2019.

MIR, R. N. et al. (Ed.). *Advancement of deep learning and its applications in object detection and recognition*. London, England: Taylor & Francis, 2023.

MIRANDA, A. S. de et al. Sintomas neurológicos agudos e residuais na malária. *Revista Brasileira de Neurologia*, v. 46, n. 3, p. 35–41, 2010. Disponível em <<http://files.bvs.br/upload/S/0101-8469/2010/v46n3/a1542.pdf>>. Acesso em 25 de março de 2026.

NASCIMENTO, M. S. *Detecção do Parasita da Malária em Filmes de Gota Espessa Utilizando Redes Neurais Rasas e Técnicas de Processamento Digital de Imagens*. Dissertação (Dissertação de Mestrado) — Universidade Federal do Amazonas, Manaus, 2023. Programa de Pós-Graduação em Engenharia Elétrica, área de concentração Controle e Automação de Sistemas e linha de pesquisa Reconhecimento de Padrões e Otimização.

OMS. *World malaria report 2022*. Genève, Switzerland: World Health Organization, 2022.

PADILLA, R.; NETTO, S. L.; SILVA, E. A. B. da. A survey on performance metrics for object-detection algorithms. In: *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*. Niterói, Brasil: [s.n.], 2020. p. 237–242.

PRIDDY, P. E. K. K. L. Artificial neural networks : an introduction. In: . [S.l.]: SPIE, 2005.

PRYCE, J. et al. Pyronaridine-artesunate for treating uncomplicated *Plasmodium falciparum* malaria. *Cochrane Libr.*, Wiley, v. 2022, n. 6, jun. 2022.

REDMON, J. et al. You only look once: Unified, real-time object detection. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.]: IEEE, 2016.

ROJAS, R. *Neural networks*. 1996. ed. Berlin, Germany: Springer, 1996.

ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological review*, American Psychological Association, v. 65, n. 6, p. 386, 1958. Disponível em <<https://www.ling.upenn.edu/courses/cogs501/Rosenblatt1958.pdf>>. Acesso em 25 de março de 2026.

RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning representations by back-propagating errors. *Nature*, Springer Science and Business Media LLC, v. 323, n. 6088, p. 533–536, out. 1986.

SYDENHAM, P. H.; THORN, R. (Ed.). *Handbook of measuring system design*. Chichester, England: John Wiley & Sons, 2005. Disponível em <http://wsc10.softcomputing.net/ann_chapter.pdf>. Acesso em 25 de março de 2026.

TERVEN, J.; CórDOVA-ESPARZA, D.-M.; ROMERO-GONZÁLEZ, J.-A. A comprehensive review of yolo architectures in computer vision: From yolov1 to yolov8 and yolo-nas. *Machine Learning and Knowledge Extraction*, v. 5, n. 4, p. 1680–1716, 2023. ISSN 2504-4990. Disponível em: <<https://www.mdpi.com/2504-4990/5/4/83>>.

VENKATESAN, K. et al. Comparative analysis of resource-efficient YOLO models for rapid and accurate recognition of intestinal parasitic eggs in stool microscopy. *Intell. Based Med.*, Elsevier BV, v. 11, n. 100212, p. 100212, 2025.

WHITE, N. J. et al. Malaria. *The Lancet*, v. 383, n. 9918, p. 723–735, 2014. ISSN 0140-6736. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0140673613600240>>.

ZHAO, Q. et al. M2Det: A single-shot object detector based on multi-level feature pyramid network. *Proc. Conf. AAAI Artif. Intell.*, Association for the Advancement of Artificial Intelligence (AAAI), v. 33, n. 01, p. 9259–9266, jul. 2019. Disponível em <<https://ojs.aaai.org/index.php/AAAI/article/view/4962>>. Acesso em 25 de março de 2026.